Ficha técnica

Pipeline de extracción verificable de PDFs contables

Versión 4 · Octubre de 2026 · Responsables: Santiago Afanador Aguello y Mariana Acero

1. Problema

Un proyecto de contaduría necesita extraer **30-40 variables** (cifras, fechas, estados, conceptos) de **~1.200 PDFs estatales de ~200 páginas** cada uno. Hasta ahora lo hacían estudiantes a mano, con tres problemas:

- **Errores humanos:** valores mal copiados o en el campo equivocado.
- **Alucinaciones:** muchos usaron chatbots que inventaban datos cuando no los encontraban, sin verificación.
- **Escaneos:** parte de los PDFs son imágenes sin texto seleccionable.

2. Solución

Un sistema que procesa los PDFs automáticamente y en lote, extrae las variables y **verifica por código que cada dato exista en el documento**. Los estudiantes pasan de digitar a solo revisar y validar.

Principio central: ningún dato llega al estudiante sin la cita exacta y la página de donde salió. Si no se encuentra, se marca NO_ENCONTRADO; nunca se inventa.

3. Pipeline

Etapa	Qué hace	Herramienta
1. Ingesta	El equipo sube los PDFs; se guardan y entran a una cola de trabajo	Next.js, NestJS, Supabase Storage, BullMQ
2. Texto y OCR	Detecta páginas digitales y escaneadas; extrae texto directo o aplica OCR, guardando cada palabra con su posición y confianza	PyMuPDF + PaddleOCR en GPU L4 (Modal)
3. Localización	Encuentra las ~10-20 páginas donde están las variables	Palabras clave y regex
4. Extracción	Reglas para datos estructurados (NIT, fechas, totales); LLM para el resto, siempre con cita literal	Python + DeepSeek V4.1 Flash
5. Verificación	Comprueba cada dato y le asigna un color	Pydantic + rapidfuzz + reglas contables
6. Revisión	Los estudiantes validan con el PDF al lado y el dato resaltado	Next.js + PDF.js

Etapa	Qué hace	Herramienta
7. Dataset final	Valores aprobados y registro de todas las correcciones	Postgres (Supabase)

4. Cómo se garantiza la veracidad

El LLM devuelve por cada variable: valor, cita literal, página y estado (ENCONTRADO / NO_ENCONTRADO). Luego el sistema verifica:

Verificación	Qué detecta
La cita existe en esa página	Alucinaciones
El valor sale de la cita	Datos que no corresponden
Formato válido (fechas, NIT con dígito de verificación, cifras normalizadas)	Errores de lectura
Coherencia contable: Activo = Pasivo + Patrimonio; subtotales suman	Cifras mal leídas por el OCR
Doble pasada en campos críticos y confianza del OCR	Datos dudosos

Color	Condición	Acción del estudiante
■ **Verde**	Pasa todo	Confirmación rápida (auditoría aleatoria 5-10%)
■ **Amarillo**	Pasa pero con alertas	Revisión obligatoria
■ **Rojo**	Falla o no encontrado	Corrección manual con el PDF a la vista

5. Stack

Capa	Tecnología	Justificación
Frontend	Next.js + PDF.js	Visor de PDF con resaltado del dato
API y cola	NestJS + BullMQ/Redis (Railway)	Procesamiento en lote, automático y reintentable
Base de datos y archivos	Supabase Pro	Postgres + almacenamiento para los 1.200 PDFs
OCR	PaddleOCR en Modal, GPU L4	Gratis y preciso en español; la GPU se cobra por segundo y se apaga sola
Extracción	DeepSeek V4.1 Flash	Muy barato; temperatura 0, sin razonamiento, horario valle
Desarrollo	Claude Pro	Asistente para construir y depurar el sistema

6. Fases

Fase	Entregable	Criterio de salida
0. Definición	Variables con tipo y regla; set de oro con los ejemplos correctos existentes	Variables aprobadas
1. Piloto OCR	OCR en Modal sobre 100 páginas escaneadas reales	Tiempo y costo por página medidos
2. Ingesta y localización	Cola, almacenamiento y detección de páginas relevantes	≥95% de páginas correctas

Fase	Entregable	Criterio de salida
3. Extracción y verificación	Reglas + DeepSeek + verificaciones	Precisión medida contra el set de oro
4. Interfaz de revisión	Visor, formulario, semáforo y registro	Piloto con estudiantes en 20-30 PDFs
5. Lote completo	1.200 PDFs procesados y asignados	Todo en revisión

7. Presupuesto (1 mes de operación)

Tasa: COP 3.220 por dólar.

Concepto	USD	COP	Justificación
DeepSeek V4.1 Flash (API)	65	209.300	Extracción con LLM; lote estimado USD 4-20, el resto para pruebas y reprocesos. Saldo prepagado
Modal, GPU L4	50	161.000	OCR de escaneos; presupuesto con colchón, costo real probable menor a USD 10
Supabase Pro	25	80.500	Base de datos y almacenamiento de PDFs
Railway	15	48.300	API, worker, Redis y frontend
Claude Pro	20	64.400	Asistente de desarrollo
Subtotal	**175**	**563.500**	
Contingencia (15%)	26,25	84.525	IVA, comisión bancaria y tasa de cambio
Total	**201,25**	**648.025**	

Salvedades

- El costo de OCR y de DeepSeek depende del piloto: tiempo real por página y tokens reales por documento. Se confirma con 50-100 documentos antes del lote.
- Cada mes adicional de operación suma ~USD 60 (COP 193.200) por Supabase, Railway y Claude Pro.
- Precios de octubre de 2026; confirmar en páginas oficiales antes de pagar.